

GRAU EN ENGINYERIA INFORMÀTICA

ESPECIALITAT EN COMPUTACIÓ

TREBALL DE FI DE GRAU

Construcció d'un dataset per a l'extracció de models de processos de negoci a partir de textos

GUILLEM PLA BERTRAN

Director
JOSEP CARMONA VARGAS

Codirector
LLUÍS PADRÓ CIRERA

Tutora del GEP
OLGA PONS PEREGORT

15/03/2022



UNIVERSITAT POLITÈCNICA DE CATALUNYA
BARCELONATECH

Facultat d'Informàtica de Barcelona



Resum

La definició formal de processos de negoci en estàndards com BPMN 2.0 és un pas crucial per a la transformació digital de les organitzacions. Moltes organitzacions tenen els seus processos documentats en text, i crear-ne els models formals té un elevat cost de personal especialitzat.

L'objectiu del projecte és crear un conjunt de dades anotades que relacionin textos amb els models formals que els descriuen, per tal que puguin ser usades per entrenar sistemes neuronals de Deep Learning per fer aquesta tasca.

S'usaran tècniques de *data augmentation* per crear textos sintètics a partir de models existents, i es realitzarà una prova de concepte amb un model neuronal simple sobre les dades obtingudes.

Índex

1	Introducció	5
2	Context	6
2.1	Problema a resoldre	6
2.2	Actors implicats	7
2.3	Business Process Model and Notation	7
2.3.1	Elements de BPMN	7
3	Justificació	12
4	Abast	14
4.1	Objectius	14
4.2	Possibles obstacles	15
5	Metodologia	16
5.1	Mètode Kanban	16
5.2	Eines	16
5.3	Validació	17
6	Planificació temporal	18
6.1	Definició de tasques	18
6.1.1	Recursos necessaris	19
6.1.2	Gestió del Projecte - GP	19
6.1.3	Generació del dataset - GD	20
6.1.4	Crear model Deep Learning - MD	21
6.1.5	Documentació - DO	22
6.2	Estimacions i Gantt	24
6.3	Plans alternatius i obstacles	26
7	Pressupost	28
7.1	Costos de personal	28
7.2	Costos per tasca	28
7.3	Costos genèrics	29
7.3.1	Maquinari	29

7.3.2	Programari	30
7.3.3	Teletreball	30
7.4	Total dels costos per personal i genèrics	31
7.4.1	Contingència	31
7.4.2	Imprevistos	31
7.5	Cost total del projecte	32
7.6	Control de gestió	32
8	Informe de sostenibilitat	33
8.1	Dimensió econòmica	33
8.2	Dimensió ambiental	34
8.3	Dimensió social	34
9	Solució plantejada	35
9.1	Eines utilitzades	35
9.1.1	Camunda	35
9.1.2	Freeling	36
9.1.3	SimpleNLG	37
9.2	Implementació	37
9.3	Solucions prèvies	37
9.4	Alternatives	37
9.5	Obstacles	37
10	Conclusions	38
	Bibliografia	39

Índex de figures

2.1	Representació dels diferents tipus d'Esdeveniments. Font: Elaboració pròpia.	8
2.2	Representació dels diferents tipus d'Activitats. Font: Elaboració pròpia. .	9
2.3	Representació dels diferents tipus de <i>Gateways</i> . Font: Elaboració pròpia. .	9
2.4	Representació dels diferents tipus de Connectors. Font: Elaboració pròpia.	10
2.5	Representació d'una <i>Swimlane</i> . Font: Elaboració pròpia.	11
4.1	Subobjectius de cada part del projecte. Font: Elaboració pròpia.	14
5.1	Metodologia Kanban. Font: Pixabay.	17
6.1	Primera part del diagrama de Gantt del projecte. Font: Elaboració pròpia.	25
6.2	Segona part del diagrama de Gantt del projecte. Font: Elaboració pròpia.	26
9.1	Logotip de Camunda. Font: camunda.com	36

Índex de taules

6.1	Taula de les tasques. Font: Elaboració pròpia.	23
7.1	Rols del projecte i la facturació per hora. Font: Elaboració pròpia.	28
7.2	Taula del cost per cada tasca. Font: Elaboració pròpia.	29
7.3	Costos del maquinari. Font: Elaboració pròpia.	30
7.4	Costos pel programari. Font: Elaboració pròpia.	31
7.5	Costos de personal i genèrics. Font: Elaboració pròpia.	31
7.6	Taula amb els costos dels imprevistos. Font: Elaboració pròpia.	32
7.7	Taula amb els costos totals del projecte. Font: Elaboració pròpia.	32

1

Introducció

El diccionari de l'Institut d'Estudis Catalans [1] defineix un procés com una manera de descabdellar-se una acció progressiva. És a dir, que qualsevol conjunt d'accions que realitzem en el nostre dia a dia es pot definir com a un procés. De la mateixa manera, en una empresa es duen a terme una llarga llista d'accions que permeten aconseguir els objectius marcats.

Evidentment, en una empresa els processos no són tan simples com els que realitzem nosaltres diàriament. En conseqüència, és molt important que cada una de les tasques estigui ben definida.

La definició formal de processos de negoci en estàndards com BPMN 2.0 és un pas crucial per a la transformació digital de les organitzacions, ja que permet gestionar els processos que es duen a terme en una empresa. Moltes organitzacions tenen els seus processos documentats en text, i crear-ne els models formals té un elevat cost de personal especialitzat.

Automatitzar la creació de diagrames BPMN seria molt útil per a les empreses. Una manera per a aconseguir això seria utilitzar models de *Deep Learning*. Malauradament, per entrenar aquests models es necessita una gran quantitat de dades que no sempre és fàcil d'aconseguir. Per evitar l'escassetat de dades, en aquest treball es pretén crear un programa que generi un *dataset* de diagrames BPMN enllaçats amb la corresponent descripció en llenguatge natural.

2

Context

Aquest treball de fi de grau (TFG) del Grau en Enginyeria Informàtica (GEI) de l'especialitat de Computació es fa amb modalitat A (centre), i es realitza en la Facultat d'Informàtica de Barcelona (FIB). El projecte pretén aprofundir en la recerca per aconseguir una millora en la creació de models BPMN a partir de textos en llenguatge natural.

2.1 Problema a resoldre

Com s'ha comentat anteriorment, el modelatge dels processos empresarials és una part vital a l'hora d'establir el funcionament d'un projecte. Moltes empreses tenen textos que expliquen com estan definits les accions a realitzar, però no ho tenen modelat en un llenguatge formal. El modelatge pot arribar a comportar fins al 60% del temps gastat en els projectes de gestió de processos.

Una possible solució per a automatitzar la creació dels diagrames a partir de descripcions en llenguatge natural és fer servir tècniques modernes d'Intel·ligència Artificial. En aquest cas concret es podria entrenar un model de *Deep Learning* a partir d'un conjunt de diagrames que tenen associat la seva descripció en llenguatge natural.

Lamentablement, tal com Matthew Stewart [2] explica, un dels reptes de l'aprenentatge automàtic és la manca de dades i la falta de bones dades. Aconseguir els conjunts de dades adequats és complex, ja que per motius de privacitat i confidencialitat molt poques empreses alliberen les descripcions dels seus processos.

En aquest projecte es pretén abordar el problema de l'escassetat de dades. Es farà generant descripcions sintètiques, que semblin mínimament reals, i que permetin entrenar algorismes de forma fiable i controlada.

2.2 Actors implicats

Els actors implicats en aquest projecte són el personal del projecte, és a dir, els directors Josep Carmona Vargas i Lluís Padró Cirera, la tutora del GEP Olga Pons Peregort i l'autor Guillem Pla Bertran.

També hi estan implicades les persones a les quals va dirigit el projecte. Aquestes són totes les persones que fan recerca en el camp de NLP o els que treballen amb BPMN en el món empresarial, principalment *Business Analysts*. Segons la Northeastern University [3] aquestes persones són les responsables d'entendre què es fa en el negoci, quins passos cal seguir per a completar els objectius, avaluar els processos per eficiència, cost i resultat, desenvolupar plans del projecte, entre altres coses.

2.3 Business Process Model and Notation

BPMN vol dir Business Process Model and Notation, en català Model i Notació de Processos Empresarials, és un estàndard per a la modelització de processos empresarials[4]. Aquest proporciona una notació gràfica per descriure un procés en un Business Process Diagram (BPD). Està basat en una tècnica de diagrama de flux molt similar als diagrames d'activitats de l'Unified Modeling Language (UML).

L'objectiu de BPMN és donar suport a la gestió de processos empresarials, tant per als usuaris tècnics com per als usuaris empresarials, per això proporciona una notació intuïtiva, però que alhora és capaç de representar una semàntica de processos complexa.

Recentment, la quantitat d'empreses que han començat a utilitzar BPMN ha crescut molt. Segons una enquesta del 2018 [5] el 64% dels negocis estan interessats en utilitzar aquest mètode per a simplificar els seus processos empresarials per a poder estalviar diners i millorar la productivitat.

A part de millorar l'eficiència hi ha altres motius que expliquen el perquè és necessari [6]. Augmenten la satisfacció dels clients, milloren la capacitat de resposta organitzativa i ajuden a complir amb noves regulacions, entre d'altres.

2.3.1 Elements de BPMN

Els models BPMN fan servir diagrames simples construïts a partir d'un conjunt d'elements gràfics. Els cinc elements bàsics que es tindran en compte en el projecte són els *Events*, les *Activities*, les *Gateways*, els *Connectors* i els *Swimlane*.

Esdeveniments

Un *Event* o Esdeveniment es representa amb un cercle i significa que alguna cosa passa durant el transcurs d'un procés. Poden tenir símbols que determinin el tipus d'esdeveniment que són. Principalment, es fan servir tres tipus d'esdeveniments:

- **Start event** o Esdeveniment inicial: És el que inicia tot el procés. Tots els processos comencen amb un esdeveniment d'aquest tipus.
- **Intermediate event** o Esdeveniment intermedi: Representa que alguna cosa passa entre l'inici i el final del procés.
- **End event** o Esdeveniment final: Representa el resultat final del procés. Tot procés té com a mínim un esdeveniment final.



Figura 2.1: Representació dels diferents tipus d'Esdeveniments. Font: Elaboració pròpia.

Activitats

Tal com explica Visual Paradigm [7], una *Activity* o Activitat és un "treball" que una empresa duu a terme en un procés de negoci. Les activitats poden ser atòmiques (Tasques) o descomponibles (Subprocessos). N'hi ha tres tipus bàsics:

- **Task** o Tasca: És una activitat atòmica dins d'un flux de processos. Es creen quan l'activitat no es pot desglossar a un nivell més detallat. En general, una persona o aplicacions duren a terme la tasca quan s'executi.
- **Sub-Process** o Subprocés: És una activitat composta que representa una col·lecció d'altres tasques i subprocessos. Per facilitar les comunicacions, no es vol que un diagrama de processos empresarials sigui complex. Mitjançant l'ús de subprocessos, és possible dividir un procés complex en diversos nivells, la qual cosa permet centrar-se en una àrea determinada d'un diagrama de procés.
- **Call Activity** o Activitat de trucada: És una activitat definida en un procés extern a la definició del procés actual. Permet crear una definició de procés que pot ser reutilitzada en altres definicions.




Figura 2.2: Representació dels diferents tipus d'Activitats. Font: Elaboració pròpia.

Gateways

Les *Gateways* o Portes d'entrada determinen quin camí s'empra a través d'un procés que controla el flux tant de fluxos de seqüències divergents com convergents. És a dir, una única porta podria tenir múltiples entrades i múltiples fluxos de sortida en els quals es permet o no l'entrada o la sortida. N'hi ha de diversos tipus, a continuació se n'explica tres dels més importants:

- **Exclusive Gateway** o Porta exclusiva: Se segueix un únic camí.
- **Parallel Gateway** o Porta paral·lela: Se segueixen tots els camins.
- **Inclusive Gateway** o Porta inclusiva: Se segueix un camí o més.



Figura 2.3: Representació dels diferents tipus de *Gateways*. Font: Elaboració pròpia.

Connectors

Els elements anteriors es connecten entre si en un diagrama per crear l'estructura bàsica d'un procés empresarial. Hi ha tres objectes de connexió que proporcionen aquesta funció. Aquests connectors són:

- **Sequence Flow** o Flux de seqüències: S'utilitza per mostrar l'ordre (la seqüència) en què es realitzaran les activitats en un procés.

- **Message Flow** o Flux de missatges: Representa el flux d'informació a través dels límits de l'organització. Els grups, les activitats i els esdeveniments de missatges es poden associar amb el flux de missatges. El flux de missatges es pot personalitzar amb un sobre que mostri el contingut del missatge.
- **Association** o Associació: Les anotacions permeten afegir més informació al diagrama que ajudi a documentar el procés.

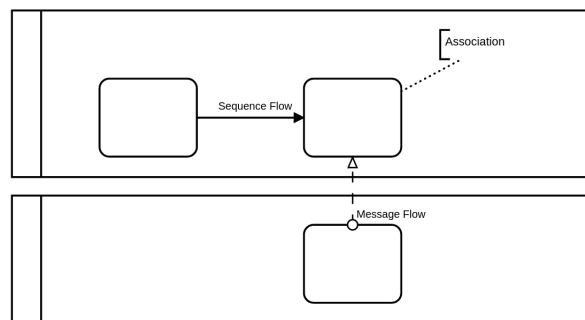


Figura 2.4: Representació dels diferents tipus de Connectors. Font: Elaboració pròpia.

Swimlane

En BPMN existeix un concepte anomenat *Swimlane*, aquest es divideix en dos tipus els *Pool* (en català, piscina), i el *Lane* (en català, carril). Un *Pool* representa un actor que pren part activa en un procés. Es representa amb un contenidor rectangular que pot contenir elements com els descrits anteriorment. Un *Lane* és una subdivisió del *Pool*, es fa servir per categoritzar activitats segons el rol o la funció de l'actor. En la figura 2.5 el *Bank* és el *Pool* i conté dos *Lane* que representen els rols de *Director* i de *Sales Department*.



Figura 2.5: Representació d'una *Swimlane*. Font: Elaboració pròpia.

3

Justificació

Donat que el modelatge de processos amb l'estàndard BPMN és molt específic l'estat de l'art no és molt extens. Tot i això, es poden trobar diverses aplicacions similars, encara que no fan ben bé el que es pretén en aquest treball. Aquests projectes fets anteriorment els podem classificar entre els que transformen d'un diagrama BPMN a text natural i els que ho fan a l'inrevés.

Abans, desenvolupar una eina que automatitzés qualsevol procés requeria molt esforç i dedicació, ja que, s'havien de tenir en compte totes les possibles combinacions en els possibles *inputs*. Això feia que en certs camps, com ara el de convertir un text natural, fos pràcticament impossible d'aconseguir. Per sort, mètodes com el *Deep Learning* permeten generar contingut de forma ràpida i eficient. Però, per aconseguir un model funcional es requereix un conjunt de dades molt gran i divers, i això no sempre és fàcil d'aconseguir.

Per a solucionar el problema plantejat en aquest treball no disposem d'un bon *dataset* que ens permeti generar un model de *Deep Learning* fiable. És per això, que la part principal d'aquest treball consisteix a crear una aplicació que generi un conjunt de dades variat i amb prou registres.

Això es farà convertint diversos diagrames a un llenguatge natural que sigui entenedor per qualsevol persona sense coneixement de BPMN. En aquest cas s'ha decidit que es farà servir l'anglès, ja que és un dels més utilitzats al món.

Per a fer aquesta primera part, hi ha un treball del 2016 titulat *Transformant Models BPMN a Llenguatge Natural* [8] que fa quelcom semblant. En el treball es llegeix el fitxer BPMN, després es crea un RSPT (Refined Program Structure Tree) per a guardar la informació necessària per solucionar el problema i també es fa servir una xarxa de Petri per a extreure l'estructura del procés. Finalment, es fa la generació del text analitzant cada element i concatenant els diferents missatges seguint l'estructura dels arbres creats anteriorment.

La segona part del projecte consisteix a entrenar una xarxa neuronal que sigui capaç d'interpretar una descripció en llenguatge natural i que ho converteixi en un model BPMN. Per a fer això, es farà servir el dataset que hem creat a la primera part. De treballs anteriors i aplicacions existents que converteixin de text a diagrames n'hi ha algunes que s'esmenten a continuació. Però cap d'elles fa servir un model de *Deep Learning*. Per tant, en aquest cas caldrà entrenar el model des de zero.

Process Talks [9] és una aplicació web que permet modelar processos a partir d'una explicació informal, sigui escrivint o parlant. L'eina fa servir regles i patrons que analitzen l'estructura sintàctica de les frases i treuen informació de qui realitza cada acció, o quina acció precedeix una altra. Aquesta implementació és costosa de mantenir i no és escalable, ja que, és complicat traspasar-la a nous idiomes. Per això, l'objectiu del projecte és crear una alternativa basada en *Machine Learning*.

A part d'aquesta aplicació web, també podem trobar un treball de recerca anomenat *Process Model Generation from Natural Language Text* [10]. Podem veure que es combinen algunes eines existents en el processament del llenguatge natural per a obtenir uns millors resultats. L'avaluació mostra que per a un conjunt de 47 parells de text-model de la indústria i els llibres de text, generen de mitjana el 77% dels models correctament.

Com s'ha pogut veure hi ha poques implementacions que serveixin de cara a plantejar una solució. Tanmateix, s'intentarà aprofitar el màxim de recursos disponibles per a reduir costos i temps.

4

Abast

4.1 Objectius

El principal objectiu del projecte és crear un conjunt de dades anotades que relacionin textos amb els models formals que els descriuen. Les dades han de servir per a ser usades per entrenar sistemes neuronals que donats un text en llenguatge natural el converteixin a un diagrama BPMN.

Com ja s'ha dit anteriorment a l'apartat de Justificació, el projecte es pot dividir en dos parts. La primera i principal és la **Generació del Dataset** i la segona és la d'**Entrenar un model** de Deep Learning com a demostració que el *dataset* és útil. En la figura 4.1 es pot veure les diferents parts del projecte i els subobjectius que té cadascuna d'elles.




Figura 4.1: Subobjectius de cada part del projecte. Font: Elaboració pròpia.

En fase de generació del dataset el que es busca és tenir un conjunt de dades amb suficients registres i amb descripcions prou variades que serveixi per a poder entrenar després un model.

Per a generar les dades cal crear un programa que llegeixi (en anglès *parse*) els elements

d'un diagrama BPMN i emmagatzemi la informació necessària en un fitxer JSON. Caldrà extreure i modificar els elements que es necessitin. Un cop fet això només caldrà fer la tria dels atributs que es volen. Després s'identificaran els verbs, objectes i complements de les frases de cada element utilitzant un software d'anàlisi lingüístic anomenat *FreeLing* [11] [12] [13] [14] [15]. Tot seguit, es procedirà a crear les descripcions en llenguatge natural, utilitzant un software de generació de llenguatge natural anomenat *SimpleNLG*[16].

Un cop s'hagi desenvolupat el programa anterior, simplement caldrà repetir el procés de generació de text per a cada un dels models BPMN i emmagatzemar el conjunt de les dades en un format adequat per a poder-ho utilitzar després.

La segona part del projecte és la de crear un model de *Deep Learning* que serveixi com a demostració que el conjunt de dades generat és utilitzable. En aquest pas s'haurà de carregar el dataset generat anteriorment, entrenar el model i provar que retorna el resultat que es vol. Si no s'ha obtingut un resultat satisfactori, es pot polir el model canviant paràmetres.

4.2 Possibles obstacles

És molt comú que quan es comença a fer un projecte es trobin obstacles i problemes que no s'havien plantejat. Quan això passa pot ser que el projecte s'endarrerixi molt. Per tant, s'ha d'intentar tenir en compte el conjunt de riscos que poden sorgir.

Un dels obstacles que pot aparèixer és que no es disposi de prou diagrames BPMN i, per tant, no poder crear un *dataset* amb gaires registres. També pot ocórrer que la utilització de llibreries no sempre funcioni correctament. En aquest cas s'haurà d'invertir molt més temps a crear alternatives. Tenir suficient informació disponible per a fer un projecte és important, i el fet que no es pugui trobar prou documentació sobre un tema és un risc a tenir en compte. A més a més, s'ha de tenir present que el temps és limitat, per tant, és possible que no sempre es puguin assolir tots els objectius marcats.

5

Metodologia

5.1 Mètode Kanban

Per a dur a terme aquest treball s'ha decidit fer servir la metodologia *Kanban*. Tal com s'explica en la web APD [17], és un sistema de producció efectiu i eficient que està dins del grup de metodologies àgils [18]. La base de les metodologies *Agile* és permetre una planificació iterativa, això implica descobrir requisits i desenvolupar solucions mentre s'avança en el desenvolupament. El principal tret de *Kanban* és l'ús de targetes visuals que ens ajuden a organitzar les tasques.

Les targetes estan definides en una web de gestió de tasques. I aquests es poden moure per definir el seu estat. S'han fet servir els següents estats:

- **To do:** Significa que la tasca encara s'ha de realitzar.
- **Doing:** Implica que la tasca s'està duent a terme.
- **Review:** Vol dir que la tasca s'ha realitzat, però el resultat pot no ser definitiu.
- **Done:** Significa que la tasca ja es dona per acabada

A més a més, la metodologia es basa a acabar la feina que ja s'ha començat i en evitar tenir diverses tasques a mitges. També permet prioritzar cada tasca, per a intentar fer de la millor forma aquelles funcionalitats que es consideren més importants.

5.2 Eines

En aquest apartat s'explica el conjunt d'eines que permetran aplicar la metodologia *Kanban* al projecte.



Figura 5.1: Metodologia Kanban. Font: Pixabay.

Per començar es necessita un controlador de versions [19], això és un software que permet guardar i gestionar una còpia de les diferents versions del programa. S'ha escollit *Git* [20] en combinació amb *GitHub* [21], què és un servei que web què permet fer ús del control de versions en línia.

Per a comprovar que el desenvolupament de les tasques es fa correctament es fa servir un servei web d'organització i gestió de tasques anomenat *Todoist* [22]. Aquest software permet definir les diferents activitats que cal accomplir en cada part del projecte i posar-les en el taulell *Kanban*. També es pot definir una data límit per a cadascuna d'elles. Així doncs, es pot saber si portem el desenvolupament al dia.

5.3 Validació

El software es revisa cada una o dos setmanes amb els directors del treball, de manera que en cas d'haver-hi algun error o dubte es pot decidir com es procedeix de forma ràpida. A més, aquesta metodologia també permet proposar canvis en el disseny del programa, de manera que es poden afegir o eliminar funcionalitats en funció del temps restant per a l'entrega.

6

Planificació temporal

Durant el transcurs del treball es va decidir endarrerir la data de finalització del treball. Aquesta va passar de ser del gener del 2022 a l'abril del 2022. Aquest canvi es va produir perquè la compaginació del projecte, amb la feina i una assignatura de la universitat va ser impossible. Això implica que s'ha tingut més dies dels que es van calcular inicialment, però el nombre estimat d'hores dedicades totals és el mateix. A continuació es mostra la planificació temporal tal com s'havia planificat a l'inici del projecte.

Un dels aspectes més importants a l'hora de dur a terme un projecte és el temps del qual es disposa. En el moment en què es redacta aquest document la data per a la finalització del treball encara no està definida, de totes maneres, es fixa el límit per acabar el projecte a principis del mes de gener del 2022. El treball es va començar el 10 de juliol del 2021. Això vol dir que es disposen de 184 dies en total per a fer el treball, inclosos caps de setmana i festius. S'estima que en un Treball de Fi de Grau (TFG) la dedicació total és de 540 h. Això implica que s'haurien de destinar unes 3 h al dia per a complir amb els objectius establerts. Evidentment, no cada dia es treballarà aquestes hores, però sí que s'haurien de fer unes 21 h setmanals.

6.1 Definició de tasques

En aquest projecte s'ha decidit dividir la feina a fer en un conjunt de tasques. Aquesta divisió permet tenir un control més gran del projecte. De manera que es pugui saber l'inici, el final i les dependències que té cada tasca. Això permet saber en tot moment si el projecte està endarrerit o no. I en cas que ho estigui, prendre les mesures oportunes.

A continuació s'expliquen els recursos necessaris per al projecte i totes les tasques i subtasques que s'han definit per al treball.

6.1.1 Recursos necessaris

S'ha determinat que els recursos necessaris per a desenvolupar el projecte són:

Humans - R1

Els recursos humans necessaris són tots dos codirectors del projecte Josep Carmona i Lluís Padró, la tutora del GEP Olga Pons i l'autor del treball o programador Guillem Pla.

Maquinari - R2

El maquinari que es fa servir és un ordinador portàtil de gamma mitjana. Aquest permet tant documentar, com programar, com entrenar el model. A més, permet la llibertat de moviments i, per tant, facilitar les reunions presencials. El portàtil utilitzat és un *Acer Aspire 3*.

Programari - R3

El software que es preveu utilitzar el *GitHub*(controlador de versions), *Todoist*(gestió del projecte), *PyCharm*(programació de projectes en Python), *IntelliJ IDEA*(programació de projectes en Java), *Google Collab*(executar codi al núvol) i *Tensorflow*(llibreria Python de machine learning).

6.1.2 Gestió del Projecte - GP

La primera part del projecte és la de gestionar de forma correcta el projecte. En aquest apartat s'hi engloben les gestions no tècniques que cal fer per a engegar el projecte. El temps total per a realitzar aquesta part s'estima en 90 hores. Aquestes són la contextualització i abast, la planificació temporal, el desenvolupament d'un pressupost, la realització de l'informe de sostenibilitat, l'elecció de la metodologia i la instal·lació del programari necessari. A continuació s'expliquen en més detall.

Contextualització i abast - GP-C

En aquesta tasca es defineixen els fonaments del projecte. Dins d'aquesta s'hi inclou la tria del tema, l'objectiu principal a resoldre, l'explicació de per què és necessari fer aquest treball i l'abast d'aquest. Per tant, una part de la feina a realitzar consisteix a fer reunions amb els directors del treball i una altra en documentar les decisions preses. S'estima que es realitza en unes 15 hores.

Planificació temporal - GP-T

Aquí es tracta de dividir el treball en tasques i d'establir un calendari per a cadascuna d'elles. Això es fa per a poder tenir, en tot moment, el control de la feina feta i la que falta per fer. S'estima que són necessàries unes 13 hores.

Metodologia - GP-M

En aquesta tasca el que es fa és estudiar el conjunt de metodologies de treball disponibles i fer una tria adequada d'una d'elles. Això permetrà seguir el calendari d'una forma més acurada. S'estima que la tasca de Metodologia es pot dur a terme en 13 hores.

Pressupost - GP-P

En aquest apartat es crea un informe on s'expliquen els termes econòmics del treball. D'acord amb les hores realitzades i amb els recursos emprats es fa un càlcul aproximat sobre el cost que té crear el projecte. Aquesta tasca es pot realitzar en unes 13 hores.

Informe de sostenibilitat - GP-S

Aquesta tasca és molt semblant a l'anterior, però en aquest cas, el que s'estudia és l'impacte mediambiental i social que el treball pot tenir. Aquesta tasca s'hauria de desenvolupar en 13 hores.

Instal·lació de programari - GP-I

Abans de començar a programar és vital decidir quines eines de software es faran servir. Per això, en aquesta tasca el que es fa és un estudi d'un conjunt d'eines disponibles al mercat i posteriorment es decideix quines es volen fer servir. Per a decidir entre un programa o un altre es té en compte la facilitat d'ús, si ja s'ha fet servir prèviament, la corba d'aprenentatge, la gratuïtat del programa i si és de codi obert. Un cop ja s'ha fet la tria només queda instal·lar totes les eines escollides. S'estima que es pot tardar unes 20 hores.

6.1.3 Generació del dataset - GD

Un cop s'ha definit el projecte a realitzar (GP-C 6.1.2) ja es pot començar el desenvolupament. La primera part consisteix a generar un conjunt de dades que permeti entrenar un model de Deep Learning. Aquest conjunt de dades constarà d'un conjunt de parelles formades per un model BPMN i un text descriptiu del model. En aquest apartat s'espera invertir unes 190 hores en total. Per a aconseguir això, es necessiten dur a terme les tasques següents.

Obtenir models BPMN - GD-O

Primer de tot, cal obtenir un conjunt de models BPMN que serveixi de base per a poder desenvolupar i testear el programa. De diagrames BPMN se'n poden trobar gratuïtament a internet, per tant, cal fer una cerca a la xarxa i descarregar-los. També és convenient comprovar que els arxius estan modelats correctament i es poden fer servir. S'estima que la durada d'aquesta tasca és d'unies 13 hores. Aquesta tasca no es pot iniciar fins que no s'hagi contextualitzat el projecte (GP-C).

Parsejar BPMN - GP-P

Després de tenir una sèrie de models descarregats, es procedeix a llegir l'arxiu que els conté, és a dir, a parsejar-los. Per a fer-ho caldrà recórrer el fitxer *.bpmn* i emmagatzemar cada element útil en un fitxer *.json*. S'estima que la durada d'aquesta tasca és d'unes 27 hores. Aquesta tasca no es pot iniciar fins que no s'hagi finalitzat la tasca d'obtenir models BPMN (GP-O).

Identificar verbs - GP-I

La tasca anterior ha permès obtenir el conjunt d'elements que conformen el model. Aquests elements sovint tenen una curta frase explicant en què consisteix la tasca del model. Aquesta frase s'utilitzarà més endavant per a generar un text natural, però abans es necessita l'anàlisi sintàctica d'aquesta frase. Per a fer-ho, es fa servir la llibreria *Freeling* que retornarà el tipus de cada paraula de la frase. Aquesta informació s'emmagatzema per a fer-la servir més endavant. S'estima que la durada d'aquesta tasca és d'unes 47 hores. Aquesta tasca no es pot iniciar fins que no s'hagi finalitzat la tasca de parsejar BPMN (GP-P).

Crear descripcions - GP-D

En aquesta tasca es crea una descripció en llenguatge natural a partir d'un diagrama BPMN. Per a fer-ho cal utilitzar la informació emmagatzemada anteriorment i fer-la servir d'input. Per a crear aquest programa es fa servir una llibreria de generació de llenguatge natural anomenada SimpleNLG. Aquest programa retornarà la descripció del model introduït. S'estima que la durada d'aquesta tasca és d'unes 70 hores. Aquesta tasca no es pot iniciar fins que no s'hagi finalitzat la tasca d'identificació de verbs (GP-I).

Crear dataset - GP-C

Al final, s'utilitzarà el programa creat en la tasca anterior per a processar múltiples diagrames. D'aquesta forma s'obtindrà per a cada model una descripció que servirà per a crear el dataset. Quan s'estigui satisfet amb el nombre de descripcions creades, s'ajunta tot en un mateix arxiu. S'estima que la durada d'aquesta tasca és d'unes 33 hores. Aquesta tasca no es pot iniciar fins que no s'hagi finalitzat la tasca de creació de descripcions (GP-D).

6.1.4 Crear model Deep Learning - MD

La segona part del desenvolupament consisteix a crear un model de Deep Learning que utilitzi el dataset creat anteriorment per a aprendre a descriure un model BPMN automàticament. En aquesta fase és les tasques d'entrenament i provar el model se superposen. Això passa perquè un cop es tingui un model entrenat s'ha de comprovar si funciona bé. En Machine Learning ja se sap que no s'obté un model funcional de seguida, per tant, s'ha de validar el model i en cas que no s'obtingui el resultat desitjat

s'haurà de generar un nou model. I així successivament. Per a realitzar el conjunt de tasques d'aquesta secció s'espera destinar unes 112 hores.

Carregar dataset - MD-C

Per a crear un model de Deep Learning primer es carrega el dataset desitjat. Així doncs, s'haurà de llegir el fitxer que conté les dades amb una llibreria adequada. En principi sembla una tasca fàcil, però la lectura de fitxers sempre pot donar problemes. I més quan el conjunt de dades ha sigut autogenerat. S'estima que la durada d'aquesta tasca és d'unes 26 hores. Aquesta tasca no es pot iniciar fins que no s'hagi finalitzat tot l'apartat de Gestió de Projectes (GP) i l'apartat de Generació del Dataset (GD).

Entrenar model - MD-E

A continuació, ja es pot entrenar el model usant les dades carregades. D'entrada, en aquesta tasca s'ha de definir quina arquitectura es vol fer servir en el model. Després es definiran uns paràmetres i es procedirà a entrenar el model predictiu. Si no s'ha obtingut uns bons resultats, es pot canviar els paràmetres amb la intenció de millorar la generació final del text, però no és necessari. S'estima que la durada d'aquesta tasca és d'unes 48 hores. Aquesta tasca no es pot iniciar fins que no s'hagi finalitzat la tasca de carregar el dataset (MD-C).

Provar model - MD-P

Aquesta tasca consisteix a comprovar si els resultats són prou bons. Com que no es tracta d'un procés de classificació automàtic validar que la sortida obtinguda és un procés manual i, per tant, costós. Aquesta tasca es durà a terme pràcticament alhora que la d'entrenar el model. S'estima que la durada d'aquesta tasca és d'unes 38 hores. Aquesta tasca no es pot iniciar fins que no s'hagi finalitzat la tasca d'entrenar un model (MD-E).

6.1.5 Documentació - DO

La documentació és una tasca molt important del treball, ja que és la que permet explicar com s'ha organitzat, realitzat i quins resultats s'ha obtingut. S'ha de dur a terme paral·lelament durant tot el desenvolupament. En aquest apartat s'espera invertir unes 120 hores en total.

Memòria - DO-M

Aquesta tasca es farà alhora que la resta del projecte i contextualitzarà el treball, es detallaran tots els passos que s'han seguit i es justificarà cada decisió presa. S'estima que la durada d'aquesta tasca és d'unes 90 hores.

Presentació - DO-P

En aquesta tasca es crearà una presentació que contindrà un breu resum del projecte elaborat. Aquesta serà un ajut visual de cara a la presentació que es faci d'aquest treball davant del tribunal que avaluï el projecte. També s'hi ha de tenir en compte el temps per a preparar l'explicació oral. S'estima que la durada d'aquesta tasca és d'unes 30 hores. La tasca no es pot iniciar fins que no s'hagi finalitzat la resta del treball (GP, GD, MD, DO-M).

Codi	Nom Tasca	Temps Estimat	Dependències Temporals	Recursos
GP-C	Contextualització i abast	15 h	-	R1, R2
GP-T	Planificació temporal	13 h	GP-C	R1, R2
GP-M	Metodologia	13 h	GP-C	R1, R2
GP-P	Pressupost	13 h	GP-C	R1, R2
GP-S	Informe de sostenibilitat	13 h	GP-C	R1, R2
GP-I	Instal·lació programari	20 h	-	R1, R2
GD-O	Obtenir models BPMN	13 h	GP-C	R1, R2, R3
GD-P	Parsejar BPMN	27 h	GD-O	R1, R2, R3
GD-I	Identificar verbs	47 h	GD-P	R1, R2, R3
GD-D	Crear descripcions	70 h	GD-I	R1, R2, R3
GD-C	Crear dataset	33 h	GD-C	R1, R2, R3
MD-C	Carregar dataset	26 h	GP, GD	R1, R2, R3
MD-E	Entrenar model	48 h	MD-C	R1, R2, R3
MD-P	Provar model	38 h	MD-E	R1, R2, R3
DO-M	Memòria	90 h	-	R1, R2
DO-P	Presentació	30 h	GP, GD, MD, DO-M	R1, R2

Taula 6.1: Taula de les tasques. Font: Elaboració pròpia.

6.2 Estimacions i Gantt

En aquest apartat s'utilitza un diagrama de Gantt per a visualitzar l'ordre i duració de cadascuna de les tasques descrites anteriorment. Un diagrama de Gantt [23] és un tipus de gràfic que il·lustra el calendari d'un projecte. Aquest diagrama mostra les tasques que s'han d'executar en l'eix vertical i en l'eix horitzontal mostra el moment d'inici, el moment de finalització i la duració de cada tasca. S'ha decidit dividir els 184 dies en 27 setmanes. Com s'ha comentat anteriorment en l'apartat de Planificació temporal 6 en cada setmana es disposa de 21 h per a executar les diferents tasques. A continuació, es mostren dos diagrames de Gantt, un per a la primera part del projecte, les primeres 13 setmanes, i un per a la segona part del projecte, corresponent a les següents 14 setmanes.




Figura 6.1: Primera part del diagrama de Gantt del projecte. Font: Elaboració pròpia.




Figura 6.2: Segona part del diagrama de Gantt del projecte. Font: Elaboració pròpia.

6.3 Plans alternatius i obstacles

En tot projecte s'ha de tenir previst que puguin aparèixer inconvenients. En conseqüència cal pensar bé quins problemes poden sorgir en cada fase del treball i proposar una solució alternativa. A continuació s'explica quins plans es poden seguir en cas que apareguin alguns obstacles.

- Un dels principals problemes que sorgeix a quasi tots els projectes és la manca de temps. Per abordar aquest obstacle s'ha decidit que no cal crear cap tasca alternativa, sinó que s'intentarà treballar més hores de les proposades per poder arribar a temps a la data límit.

També s'ha tingut present això a l'hora d'assignar la càrrega a cada tasca. Es pot veure que el temps estimat total per a la realització del projecte és d'unes 509 hores, però en TFG s'haurien de dedicar unes 540 hores. Llavors es té unes 31 hores que es poden realitzar de més i continuar acabant a temps el pla.

A més, en l'anàlisi de temps dedicat a cada tasca també s'ha tingut en compte que entrenar i provar el model no sortirà bé de seguida. Per tant, en els temps estimats ja té en compte que es pugui tardar a obtenir un resultat desitjable.

- Un altre dels problemes que pot sorgir és que la informació sobre el tema del treball no sigui gaire extensa, això suposa un problema per què costa més entendre com s'ha de procedir. La solució és espremer al màxim la informació disponible i aprendre a partir de la investigació pròpia.
- Un altre problema que pot sorgir és que el dataset creat no sigui prou divers o que no es tinguin gaires models BPMN per a crear el dataset. Si un d'aquests casos apareix, implicaria que mai es podria obtenir un bon model de Deep Learning. Com que això no és tolerable s'hauria de crear una nova tasca anomenada Crear models BPMN inventats (GD-O). Es tractaria d'usar *data augmentation* per a obtenir més models BPMN i així intentar aconseguir un dataset més divers. Evidentment, això és complicat de realitzar i no garanteix uns bons resultats, però s'hauria de provar. La realització d'aquesta tasca podria durar unes 15-25 hores.
- L'últim possible obstacle que s'ha analitzat és que no es disposi de recursos suficients per a entrenar el model. En aquest cas, la solució proposada és executar el codi en servidors al núvol amb més velocitat de processament que les nostres màquines en local. Aquests podran ser tant de pagament com gratuïts. S'intentarà utilitzar sempre l'opció més econòmica. Si cal fer servir aquests serveis, no comportarà un temps afegit, ja que, la posada a punt d'aquests servidors és molt ràpida i intuïtiva.

Pressupost

En aquest apartat s'elabora una anàlisi econòmica del projecte amb la finalitat de decidir si és factible dur-lo a terme. Cal analitzar i estimar les següents classes de costos: costos de personal, costos de les tasques, maquinari, programari i costos d'espai de treball. També s'ha de tenir en compte els possibles contratemps que puguin sorgir i fer una estimació del que poden costar. A continuació es detallen les classes esmentades.

7.1 Costos de personal

Abans de res, s'ha de definir quins rols hi ha involucrats en el projecte. En aquest cas, hi ha el càrrec de Cap de Projecte, que és la persona encarregada de planificar, supervisar i dirigir-lo durant la realització d'aquest. És un rol compartit entre els codirectors del TFG i l'autor d'aquest. També existeix el rol de programador, que és la persona que dissenya, escriu i depura el codi del projecte. En aquest cas el rol només l'executa l'autor del TFG.

A la taula 7.1 es pot veure el sou brut, el que s'ha de pagar de Seguretat Social (SS) i la retribució total de cadascun dels càrrecs esmentats anteriorment. Els sous bruts han sigut extrets de la pàgina web Glassdoor [24].

Rol	Sou brut	SS	Retribució
Cap de projecte	22,5 €/hora	6,75 €/hora	29,25 €/hora
Programador	12 €/hora	3,6 €/hora	15,6 €/hora

Taula 7.1: Rols del projecte i la facturació per hora. Font: Elaboració pròpia.

7.2 Costos per tasca

El temps de desenvolupar cada tasca és diferent, per tant, cal calcular per a cada una de les activitats el seu cost. El temps de cada tasca està descrit a l'apartat de Planificació temporal 6. També cal considerar que cada tasca pot ser desenvolupada pel Cap del

Projecte o pel Programador. Les activitats associades a la Gestió del Projecte (GP) 6.1.2 i a la Documentació 6.1.5 les durà a terme íntegrament el Cap del Projecte. Les tasques de Generació del Dataset 6.1.3 les desenvoluparà el Programador. En canvi, les tasques d'Entrenament del Model 6.1.4 les faran el Cap del Projecte i el Programador, això sí, el Programador és el que hi ha d'invertir més temps. En aquestes tasques el Cap del Projecte simplement ajudarà a dissenyar el model i decidirà si és correcte o no.

Codi	Nom Tasca	Cap del projecte	Programador	Cost
GP-C	Contextualització i abast	15 h	0 h	438,75 €
GP-T	Planificació temporal	13 h	0 h	380,25 €
GP-M	Metodologia	13 h	0 h	380,25 €
GP-P	Pressupost	13 h	0 h	380,25 €
GP-S	Informe de sostenibilitat	13 h	0 h	380,25 €
GP-I	Instal·lació programari	0 h	20 h	312,00 €
GD-O	Obtenir models BPMN	0 h	10 h	156,00 €
GD-P	Parsejar BPMN	0 h	14 h	218,40 €
GD-I	Identificar verbs	0 h	31 h	483,60 €
GD-D	Crear descripcions	0 h	47 h	733,20 €
GD-C	Crear dataset	0 h	28 h	436,80 €
MD-C	Carregar dataset	0 h	36 h	561,60 €
MD-E	Entrenar model	16 h	56 h	1.341,60 €
MD-P	Provar model	12 h	52 h	1.162,20 €
DO-M	Memòria	90 h	0 h	2632,50 €
DO-P	Presentació	30 h	0 h	877,50 €

Taula 7.2: Taula del cost per cada tasca. Font: Elaboració pròpia.

En la taula 7.2 s'hi troba el codi i nom de totes les tasques que s'han de realitzar. També s'hi veu el temps que hi dediquen tant el Cap del Projecte com el Programador. I finalment també hi ha el cost total de cada tasca, aquest s'ha calculat en funció del preu per hora calculat a la taula 7.1. En total el cost de totes les tasques és de 10.875,15 €.

7.3 Costos genèrics

En aquest apartat s'expliquen els costos genèrics que té el projecte. Aquests costos són la suma dels costos de maquinari, de programari i del teletreball. A continuació es detallen cadascun d'ells.

7.3.1 Maquinari

En tot projecte informàtic es necessita un maquinari per a dur-lo a terme. En aquest cas s'ha fet servir un monitor *Newskill Icarus RGB IC27QRS 27"*, un portàtil *Acer Aspire 3 A315-51-59SU*, un ratolí *Logitech G603* i un teclat *Logitech G213*. A la taula 7.3 s'hi veu

el seu preu de mercat l'octubre del 2021 i també el seu cost amortitzat. Per a calcular el cost amortitzat s'ha de tenir en compte que el maquinari té un temps de vida estimat de 4 anys. Per a fer el càlcul de les hores reals que permet treballar cada eina cal tenir en compte que un any disposa d'uns 231 dies hàbils (251 dies laborables menys 20 dies de vacances) i que 1 dia hàbil compta de 8 hores. Com ja s'ha explicat a l'apartat de Planificació 6, es calcula que es farà servir aquestes eines unes 540 hores. Per tant, la fórmula que es fa servir és la següent.

$$4 \text{ anys} \cdot 231 \text{ dies laborables} \cdot 8 \text{ hores} = 7392 \text{ hores hàbils}$$

$$\frac{540 \text{ hores de projecte}}{7392 \text{ hores hàbils}} = 0,073$$

Per tant, es multiplica el preu de mercat de cada producte per 0,073 per a obtenir el cost amortitzat.

Nom del maquinari	Preu de mercat	Cost amortitzat
Monitor	239 €	17,45 €
Portàtil	519 €	37,89 €
Ratolí	49 €	3,50 €
Teclat	62 €	4,53 €
Total	869 €	63,37 €

Taula 7.3: Costos del maquinari. Font: Elaboració pròpia.

7.3.2 Programari

Actualment, al mercat hi ha disponible una gran quantitat de programari. Aquest pot ser gratuït o de pagament. Normalment, es pot trobar software gratuït de qualitat que ens permet executar la tasca i a més estalviar diners. Per a dur a terme aquest treball s'ha intentat reduir al màxim els costos de programari. És per això que el llistat de programes que es mostra a la taula 7.4 és totalment gratuït. Alguns dels serveis que es faran servir també tenen una versió de pagament, però en principi amb la versió més bàsica d'aquests ens és suficient. També és important comentar que el *PyCharm Edu* és només gratuït per a estudiants, com que l'autor d'aquest treball ho és es pot fer servir, si no ens costaria 19,90 € al mes.

7.3.3 Teletreball

Com que el treball es realitza en mig d'una pandèmia, és millor evitar els espais públics i, per tant, el treball es fa íntegrament a casa. S'ha de calcular quant costa el fet d'estar teletreballant a casa. Això implica el mobiliari (taules, cadires, etc.), la llum, el lloguer i altres despeses. Alguns sindicats laborals [25] ja estan calculant quant costa el fet de treballar des de casa, i han arribat a la conclusió que aquestes despeses arriben a uns 21 € al mes. Per tant, si el projecte es desenvolupa en 7 mesos, el cost total és de 147 €.

Nom programari	Cost mensual	Mesos utilitzats	Cost total
Python	0 €	6	0 €
PyCharm Edu	0 €	6	0 €
IntelliJ IDEA Community	0 €	6	0 €
Overleaf	0 €	7	0 €
Clockify	0 €	7	0 €
Github	0 €	7	0 €
Tensorflow	0 €	3	0 €
Google Colab	0 €	3	0 €

Taula 7.4: Costos pel programari. Font: Elaboració pròpia.

7.4 Total dels costos per personal i genèrics

En la taula 7.5 s'hi poden veure el total dels costos del personal i els costos genèrics calculats anteriorment.

Concepte	Cost
Personal	10.875,15 €
Maquinari	63,37 €
Programari	0,00 €
Teletreball	147,00 €
Total	11.085,52 €

Taula 7.5: Costos de personal i genèrics. Font: Elaboració pròpia.

7.4.1 Contingència

Cal tenir present que durant el projecte surtin dificultats i adversitats. Aquestes poden fer que el cost final del projecte s'encareixi. Per tant, cal estar preparats per si passa. Es prepara una partida de contingència, o marge de seguretat, que permetrà cobrir els imprevistos no anticipats. Es calcula com un percentatge del total del pressupost.

En els projectes de desenvolupament software s'acostuma a reservar entre un 10% i un 20% del pressupost. Com que es té un nivell de detall del pressupost òptim, només s'hi destinarà el 10%. Per tant, el cost total de la contingència es calcula així:

$$\text{Cost total} \cdot 10\% = 11.085,52 \cdot 10\% = 1.108,55 \text{ €}$$

7.4.2 Imprevistos

En darrer terme també s'ha de considerar les activitats que formen part dels plans alternatius. Aquestes activitats no es costegen totalment, sinó que es fa segons el percentatge

estimat de risc que tinguin cadascuna d'elles. A la taula 7.6 es veuen els possibles imprevistos que poden sorgir, l'increment de cost que suposarien i el cost que finalment es reserva.

Imprevist	Cost	Risc	Total
Nou ordinador	500,00 €	5%	25,00 €
Increment del temps d'entrenament (20h)	339,30 €	20%	67,86 €
Google Collab Pro (5 mesos)	49,95 €	10%	4,99 €
Total	889,25 €		97,86 €

Taula 7.6: Taula amb els costos dels imprevistos. Font: Elaboració pròpia.

7.5 Cost total del projecte

En la taula 7.7 s'hi calcula el cost total d'aquest.

Concepte	Cost
Tasques	10.875,15 €
Maquinari	63,37 €
Programari	0,00 €
Teletreball	147,00 €
Contingència	1.108,55 €
Imprevistos	97,86 €
Total	12.291,93 €

Taula 7.7: Taula amb els costos totals del projecte. Font: Elaboració pròpia.

7.6 Control de gestió

Per a evitar sorpreses en el cost s'ha de realitzar un control dels costos. Es tracta d'avaluar les possibles desviacions que hi hagi durant el transcurs del projecte. Es comparen els costos reals que s'hagin tingut al treball amb el pressupostat. En cas de detectar una desviació cal saber en quines activitats o etapes ha ocorregut, explicar el perquè ha passat i quina quantitat.

En cas que es produeixin desviacions en tasques mencionades a l'apartat d'imprevistos 7.4.2 s'utilitzarà la partida destinada a cobrir aquests contratemps. Si no fos suficient o les desviacions fossin d'una tasca que no s'ha tingut en compte s'hauria de fer servir el fons de contingència. Les fórmules que s'utilitzen per a fer el seguiment són les següents:

$$\frac{\text{cost estimat} - \text{cost real}}{\text{hores estimades} - \text{hores reals}}$$

Informe de sostenibilitat

Un cop respost el qüestionari del projecte EDINSOST [26] sóc més conscient del grau de coneixement que tinc respecte a la sostenibilitat. Actualment, es posa molt èmfasi en la sostenibilitat, el canvi climàtic i el medi ambient, això fa que es tinguin coneixements teòrics generals sobre aquests temes. Malgrat tot, els coneixements pràctics necessaris per a acomplir un projecte de forma sostenible no els tinc.

Això implica que a l'hora de detectar que un element del treball no és sostenible ho puc fer amb certa facilitat. Però, no tinc prou coneixements per a mesurar-ho amb els indicadors adequats. També es fa difícil proposar alternatives més sostenibles, ja que ignoro les tècniques que es fan servir actualment.

Pel que fa a l'impacte social que un servei TIC pot tenir em considero capacitat per a avaluar el paper que juga aquest projecte en la societat. Tant en l'àmbit de l'accessibilitat, i la qualitat ergonòmica com per la justícia social, l'equitat i la diversitat. En aquest cas també em considero capaç de proposar mesures eficaces per a millorar en aquests àmbits. Encara que també costa fer servir indicadors per a estimar com un projecte contribueix a millorar el bé comú de la societat.

Respecte a la dimensió econòmica no comprenc gaire bé les parts econòmiques d'un projecte, ja que és un àmbit molt extens, però sí que en tinc alguna idea.

I per finalitzar, considero que sé valorar els beneficis del treball en equip en les TIC, i a més, conec les eines necessàries per a desenvolupar projectes amb més gent.

8.1 Dimensió econòmica

En l'apartat de Pressupost 7 s'ha detallat el cost del projecte i dels seus apartats per a tenir clar quines són les seccions amb una partida pressupostària més alta. Com s'ha explicat, s'ha intentat que tinguin un cost mínim. Això implica fer servir programari

gratuït i utilitzar maquinari que no sigui de gamma màxima.

El punt on més diners es destinen és en els costos personals. Evidentment, aquests no es poden reduir més, ja que el sou dels treballadors ha de ser just i les hores que han de fer ja estan marcades per les característiques del TFG. En conseqüència, s'ha aconseguit que el cost estimat per a la realització del projecte sigui adequat.

Pel que fa a les solucions actuals, el projecte també pretén millorar-les en l'aspecte econòmic. Aquesta solució permetrà estalviar diners als usuaris d'aquest servei, ja que no es necessitarà tant personal qualificat per a realitzar els models BPMN.

8.2 Dimensió ambiental

La dimensió ambiental de la realització del projecte s'estima que serà baixa. Això es deu al fet que no s'utilitza maquinari que consumeixi grans quantitats d'energia. A més, el treball es duu a terme plenament des de casa i, per tant, no es fan desplaçaments innecessaris que podrien tenir un cost ambiental elevat. Tampoc es produeixen residus, ja que el poc paper que es fa servir és o bé reciclat o bé reutilitzat.

Respecte a la seva vida útil aconsegueix reduir l'impacte que tenen les alternatives actuals. Amb l'ús de la solució plantejada en aquest projecte es redueix l'impacte ambiental, ja que es podrà reduir personal que treballi a fer models manualment. Això implica una reducció en desplaçaments, en espai de treball i en llum a les oficines.

8.3 Dimensió social

En l'àmbit personal crec que el projecte m'aportarà coneixements tècnics en el sector del Deep Learning, coneixements sobre realitzar correctament un projecte d'enginyeria informàtica, capacitat per a entendre què són els models de processos empresarials, aprendre a gestionar millor les tasques, millorar la capacitat per a executar projectes a temps, també em proporcionarà experiència a l'hora de programar.

La utilitat d'aquest treball a nivell col·lectiu es basa en el fet que les empreses que facin servir BPMN podran reduir la quantitat de feina que els *Business Analysts* han de fer, i, per tant, podran dedicar més temps a altres coses més necessàries. També pot ser que a la llarga es requereixin menys treballadors en una empresa fent aquesta feina, per a la persona que es dedica a això pot ser un problema, però al final la tecnologia sempre ha implicat canvis en totes les professions.

Solució plantejada

En aquest apartat es detalla com s'ha implementat la solució al problema. A més, s'hi comenten els canvis que s'han hagut de fer respecte a la planificació inicial, i els obstacles que han obligat a fer aquestes modificacions.

Com que aquest projecte compta de diverses etapes, s'ha decidit desenvolupar cada etapa com a un petit programa que sigui independent dels altres. D'aquesta manera s'aconsegueix que el codi sigui més modular, per tant, tal com s'explica en la web *Software Design Principles* [27], el codi és més fàcil d'ampliar, provar, corregir errors i reutilitzar.

9.1 Eines utilitzades

Tal com afirma Madhuri Hammad [28] en la web *Geeks for Geeks*, és important no reinventar la roda quan es desenvolupa un projecte de *Software*. Això vol dir que no cal programar de zero una eina, se'n pot fer servir una que ja ha estat inventada.

En aquest treball s'ha decidit fer servir un conjunt d'eines que permeten agilitzar algunes fases del treball i no malbaratar temps i recursos. A continuació, s'expliquen les eines que s'han fet servir.

9.1.1 Camunda

Camunda Platform [29] és un sistema de flux de treball i de suport a decisions de codi obert. Aquesta plataforma conté eines per a crear fluxos de treball i models de decisió. També permet als usuaris executar les tasques dels fluxos de treball [30]. Ells mateixos expliquen que el seu objectiu és permetre a empreses dissenyar, automatitzar i millorar els seus processos empresarials. Ha estat desenvolupat en Java i es pot fer servir en qualsevol sistema operatiu que admeti aquest llenguatge.



Figura 9.1: Logotip de Camunda. Font: camunda.com

Tal com explica Charles Humble [31] aquesta plataforma té un motor de processament de models BPMN 2.0 implementat en Java. Consta també de *Cockpit*, una eina de seguiment i administració. Un *plugin* per a *Eclipse* i un producte anomenat *Cycle* que es fa servir per sincronitzar diagrames BPMN amb els executables desenvolupats amb *Modeler*.

Com es pot veure, *Camunda Platform* és una eina molt completa, tanmateix, en aquest projecte només es fa servir com a *parser* dels models BPMN. És a dir, l'eina s'utilitza per a llegir els diagrames emmagatzemats en XML i convertir-los en objectes de Java. Aquests contenen mètodes de consulta que permeten extreure els atributs que es consideren més importants i després guardar-los en una altra estructura de dades. En aquest cas, es guarden en un fitxer JSON.

9.1.2 Freeling

Tal com s'ha explicat en l'apartat Abast 4 en aquest treball també es fa servir *FreeLing* [11] [12] [13] [14] [15]. És un projecte de codi obert dirigit per Lluís Padró, un dels directors d'aquest treball. Es va crear amb l'objectiu de compartir amb la comunitat els resultats de la recerca realitzada pel grup de recerca en processament del llenguatge natural de la UPC. *FreeLing* es desenvolupa i es manté pel Centre de Recerca TALP [32], a la Universitat Politècnica de Catalunya. També rep moltes contribucions externes de part de la comunitat.

És una llibreria de *C++* que permet l'anàlisi del llenguatge en molts idiomes. Alguns d'aquests idiomes són l'anglès, el català, el portuguès, el rus, l'alemany, el castellà, entre d'altres. Alguns dels principals serveis que inclou aquesta llibreria són la *tokenització* de text, divisió de frases, una anàlisi morfològica, reconeixement de paraules compostes, etiquetatge PoS, etc.

En aquest projecte es fa servir una versió modificada del *Freeling* que utilitza una gramàtica per a buscar frases en forma d'accions, com per exemple "enviar missatge al client". Aquesta adaptació retorna un JSON amb informació sobre el predicat, l'objecte directe i altres complements de la frase. També retorna informació sobre el gènere,

el número, el temps del nucli de cada component de l'acció.

9.1.3 SimpleNLG

SimpleNLG [16] és una API de Java per a generar textos en llenguatge natural. El codi original va ser desenvolupat per Ehub Reiter al departament de ciències de la computació de la universitat d'Aberdeen, però com que és un projecte de codi obert, ha tingut diverses contribucions per part de la comunitat. També existeix una versió de l'API per a Python, desenvolupada per Brad Jascob [33]. Aquesta adaptació és pràcticament igual a l'original, malgrat tot, no totes les classes i els mètodes han pogut ser replicats.

Aquesta eina implementa un sistema lèxic i morfològic que calcula les formes flexionades, un realitzador que genera textos de forma sintàctica, i un microplanificador. Originalment, es va desenvolupar per a crear textos en anglès, avui en dia ja funciona amb el francès, l'italià, el brasiler, el neerlandès, l'alemany o el gallec.

En aquest projecte es fa servir la funcionalitat del *realiser* o realitzador. Aquesta permet crear frases a partir de crides a funcions. Amb les dades obtingudes anteriorment pel *Freeling* 9.1.2 es genera una frase nova. La utilitat d'això és que es pot ajuntar la persona que realitza l'acció (*lane*) amb la mateixa acció (text de l'element BPMN) i crear una frase amb sentit. Després aquestes frases es concatenaran per a formar paràgrafs que descriuran el procés BPMN.

9.2 Implementació

9.3 Solucions prèvies

9.4 Alternatives

9.5 Obstacles

10

Conclusions

Bibliografia

- [1] Institut d'Estudis Catalans. Diec2. <https://dlc.iec.cat/>. Accedit el 26/09/2021.
- [2] Matthew Stewart. The limitations of machine learning. <https://towardsdatascience.com/the-limitations-of-machine-learning-a00e0c3040c6>. Accedit el 15/03/2022.
- [3] Ashley DiFranza. What does a business analyst do? <https://www.northeastern.edu/graduate/blog/what-does-a-business-analyst-do/>. Accedit el 26/09/2021.
- [4] Wikipedia. Business process model and notation. https://en.wikipedia.org/wiki/Business_Process_Model_and_Notation. Accedit el 20/08/2021.
- [5] Beyond BPMN. Beyond bpmn. <https://beyondbpmn.com/>. Accedit el 24/08/2021.
- [6] Marin Perez. The beginner's guide to using bpmn in business. <https://www.microsoft.com/en-us/microsoft-365/business-insights-ideas/resources/the-guide-to-using-bpmn-in-your-business>. Accedit el 24/08/2021.
- [7] Visual Paradigm. Bpmn activity types explained. <https://www.visual-paradigm.com/guide/bpmn/bpmn-activity-types-explained/>. Accedit el 16/10/2021.
- [8] Genís Martín Coca. Transformant models bpmn a llenguatge natural, 2016.
- [9] Josep Carmona, Lluís Padró, Marc Solé, and Sànchez-Ferreres Josep. Process talks. <https://www.processtalks.com/>. Accedit el 26/09/2021.
- [10] Fabian Friedrich, Jan Mendling, and Frank Puhlmann. Process model generation from natural language text. *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 6741 LNCS:482–496, 2011.
- [11] Lluís Padró, Miquel Collado, Samuel Reese, Marina Lloberes, and Irene Castellón. Freeling 2.1: Five years of open-source language processing tools. In *Proceedings of 7th Language Resources and Evaluation Conference (LREC'10)*, La Valletta, Malta, May 2010.

- [12] Lluís Padró. Analizadores multilingües en freeling. *Linguamatica*, 3(2):13–20, December 2011.
- [13] Lluís Padró and Evgeny Stanilovsky. Freeling 3.0: Towards wider multilinguality. In *Proceedings of the Language Resources and Evaluation Conference (LREC 2012)*, Istanbul, Turkey, May 2012. ELRA.
- [14] Xavier Carreras, Isaac Chao, Lluís Padró, and Muntsa Padró. Freeling: An open-source suite of language analyzers. In *Proceedings of the 4th International Conference on Language Resources and Evaluation (LREC'04)*, 2004.
- [15] Jordi Atserias, Bernardino Casas, Elisabet Comelles, Meritxell González, Lluís Padró, and Muntsa Padró. Freeling 1.3: Syntactic and semantic services in an open-source nlp library. In *Proceedings of the fifth international conference on Language Resources and Evaluation (LREC 2006)*, Genoa, Italy, May 2006. ELRA.
- [16] Ehud Reiter. simplenlg. <https://github.com/simplenlg/simplenlg>.
- [17] Max Rehkopf. What is a kanban board? — atlassian. <https://www.atlassian.com/agile/kanban/boards>. Accedit el 18/12/2021.
- [18] Wikipedia. Agile software development. https://en.wikipedia.org/wiki/Agile_software_development. Accedit el 28/09/2021.
- [19] Wikipedia. Version control. https://en.wikipedia.org/wiki/Version_control. Accedit el 16/10/2021.
- [20] Wikipedia. Git. <https://en.wikipedia.org/wiki/Git>. Accedit el 16/10/2021.
- [21] Wikipedia. Github. <https://en.wikipedia.org/wiki/GitHub>. Accedit el 16/10/2021.
- [22] Todoist. Features. <https://todoist.com/features>. Accedit el 16/10/2021.
- [23] Wikipedia. Gantt chart. https://en.wikipedia.org/wiki/Gantt_chart. Accedit el 03/10/2021.
- [24] Glassdoor. Sueldo: Programador en barcelona. https://www.glassdoor.es/Sueldos/barcelona-programador-sueldo-SRCH_IL.0,9_IM1015_K010,21.htm?clickSource=searchBtn. Accedit el 10/10/2021.
- [25] CSIF, APT, UGT, CCOO, and Intersindical-CSC. Comunicado conjunto: Negociación de teletrabajo. <https://csifcapgemini.blogspot.com/2021/10/comunicado-conjunto-negociacion-de.html>. Accedit el 10/10/2021.
- [26] Instituto universitario de investigación en Ciencia y Tecnologías de la Sostenibilidad. Edinsost, proyecto de innovación educativa — instituto universitario de investigación en ciencia y tecnologías de la sostenibilidad — upc. universitat politècnica de catalunya. <https://is.upc.edu/es/noticias/edinsost>. Accedit el 15/10/2021.

- [27] Software Design Principles. Top 5 principles of software development. <https://www.educba.com/software-design-principles/>. Accedit el 09/03/2022.
- [28] Hammad Madhuri. Principles of software design — geeksforgeeks. <https://www.geeksforgeeks.org/principles-of-software-design/>. Accedit el 09/03/2022.
- [29] Camunda. Workflow and decision automation platform. <https://camunda.com/>. Accedit el 16/10/2021.
- [30] Wikipedia. Camunda. <https://en.wikipedia.org/wiki/Camunda>. Accedit el 09/03/2022.
- [31] Charles Humble. Camunda forks alfreco activiti. <https://www.infoq.com/news/2013/03/Camunda-Forks-Activiti/>. Accedit el 09/03/2022.
- [32] TALP. Language and speech technologies and applications. <https://www.talp.upc.edu/>. Accedit el 10/03/2022.
- [33] Brad Jascob. pysimplenlg. <https://github.com/bjascob/pySimpleNLG>. Accedit el 11/03/2022.